Agent_crawl – Technical Documentation

1. Tổng quan dự án

1.1 Mục tiêu

Dự án **Agent_crawl** được xây dựng nhằm tự động hóa quá trình thu thập dữ liệu từ các nguồn web (RSS feed, sitemap), phân loại nội dung và lưu trữ có cấu trúc trong cơ sở dữ liệu.

Mục tiêu chính:

- Giảm tải công việc thu thập dữ liệu thủ công.
- Tạo nền tảng cho các hệ thống phân tích thông tin (ví dụ: phát hiện CVE, tin tức bảo mật).
- Dễ dàng mở rộng thêm nguồn dữ liệu mới.

1.2 Công nghệ sử dụng

Thành phần	Công nghệ
Ngôn ngữ	Go
Cơ sở dữ liệu	PostgreSQL
Cấu hình	YAML
Kiến trúc	Modular CLI-based
Triển khai	Local hoặc container hóa (Docker)

2. Kiến trúc hệ thống

2.1 Tổng quan

Hệ thống được thiết kế theo mô hình **modular architecture**, chia thành các thành phần độc lập:

- **Scheduler**: đọc RSS/sitemap, tạo task crawl.
- **Task Queue**: lưu trữ các task chờ xử lý.
- **Worker**: thực hiện crawl, phân loại và lưu dữ liệu.
- **Migration Module**: tạo và cập nhật schema DB.
- **Command Interface**: cung cấp CLI để điều khiển toàn bộ hệ thống.
- **Config Management**: quản lý cấu hình qua `config.yaml`.

2.2 Sơ đồ UML kiến trúc

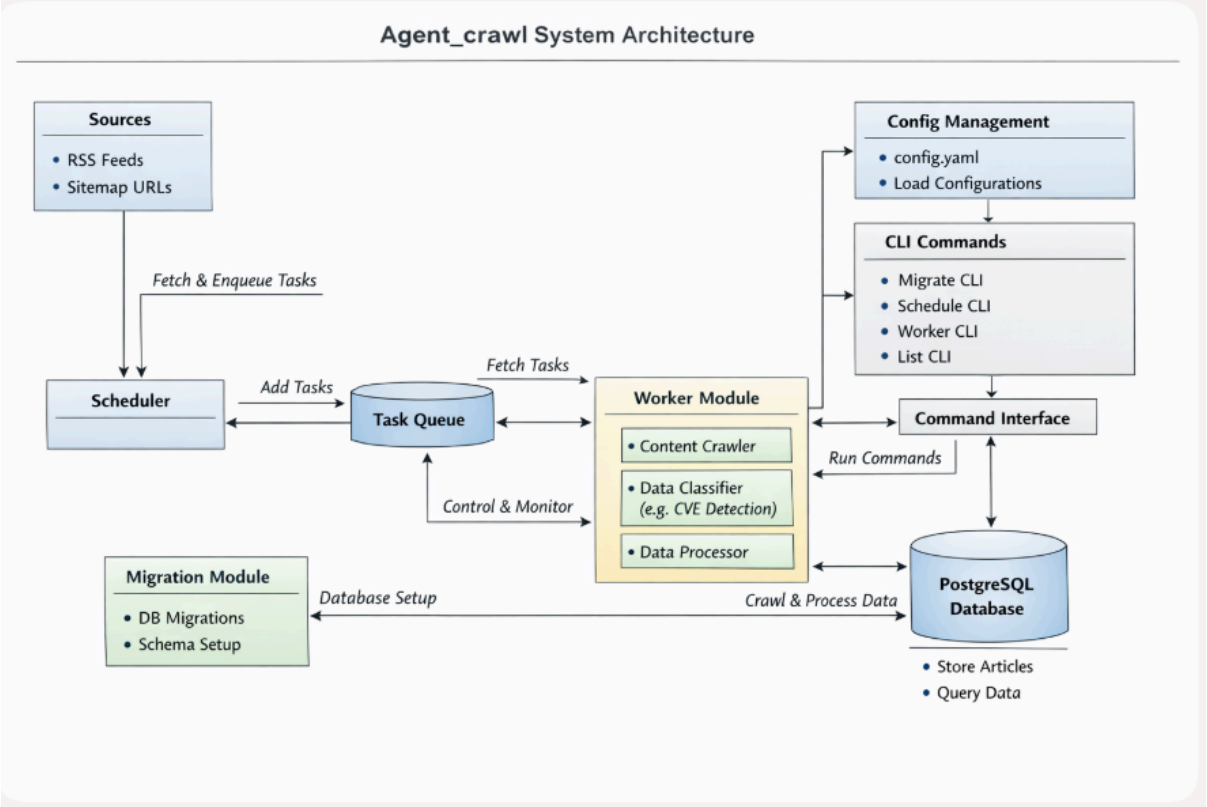

Sơ đồ thể hiện mối quan hệ giữa các module: từ nguồn dữ liệu → Scheduler → Queue → Worker → Database, cùng các thành phần hỗ trợ CLI và cấu hình.

3. Thiết kế kỹ thuật (Technical Design)

3.1 Cấu trúc thư mục

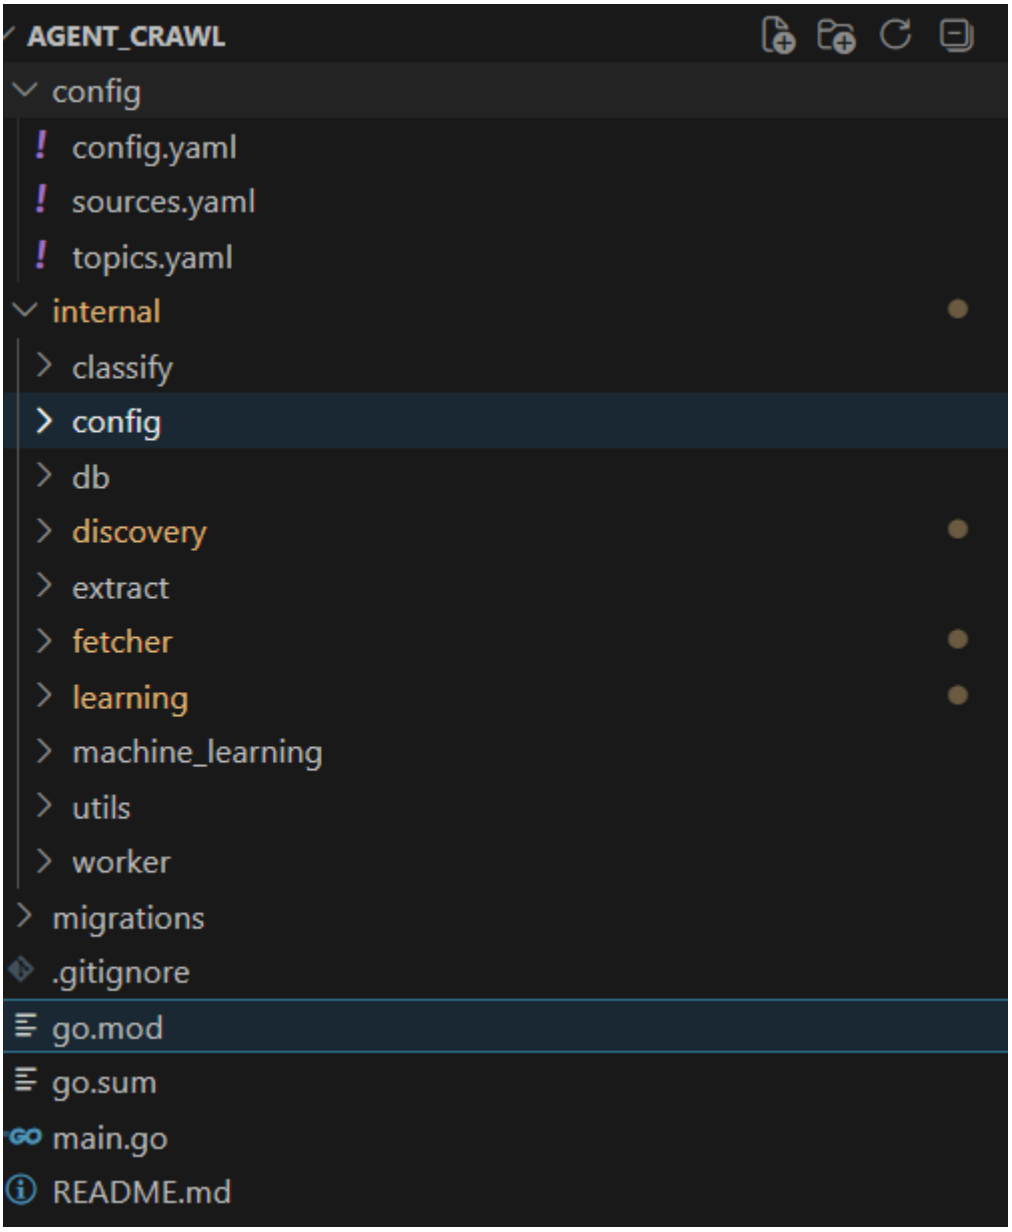

3.2 Cấu hình hệ thống

File `config.yaml` chứa:

Yaml Sao chép

```yaml
database_url: "postgres://user:password@localhost:5432/agent_crawl"
sources:
  rss: true
  sitemap: true
```

3.3 Cơ sở dữ liệu

- **Bảng chính:** `documents`, `queues`, `sources`.
- **Migration:** thực hiện qua CLI `migrate`.
- **Quan hệ:**
  - Một nguồn có nhiều bài viết.
  - Một task tương ứng với một bài viết cần crawl.

4. Quy trình hoạt động

4.1 Sequence Diagram (Luồng hoạt động)

1. Người dùng chạy lệnh `schedule`.
2. Scheduler đọc RSS/sitemap, tạo danh sách URL.
3. Mỗi URL được enqueue vào Task Queue.
4. Người dùng chạy lệnh Worker
5. Worker lấy task, crawl nội dung, phân loại dữ liệu.
6. Kết quả được lưu vào PostgreSQL.
7. Người dùng có thể xem dữ liệu qua lệnh `list`.

5. Các tính năng chính

Tính năng	Mô tả
Crawl RSS/Sitemap	Thu thập dữ liệu từ nhiều nguồn
Task Queue	Quản lý tiến trình crawl
Worker	Xử lý song song, phân loại dữ liệu
Migration	Tự động tạo schema DB
CLI Commands	Điều khiển toàn bộ hệ thống
Configurable Sources	Dễ dàng thêm nguồn mới

6. Triển khai và vận hành

6.1 Cài đặt

Bash Sao chép

```bash
git clone https://github.com/kien5217/Agent_crawl.git
cd Agent_crawl
go mod tidy
```

6.2 Chạy hệ thống

```bash
go run main.go migrate --config ./config/config.yaml
go run main.go schedule --config ./config/config.yaml
go run main.go worker --config ./config/config.yaml
go run main.go list cve 100 --config ./config/config.yaml
```

I

6.3 Logging & Monitoring

- Log được ghi ra console.
- Có thể mở rộng sang file hoặc hệ thống giám sát (Prometheus, Grafana).